

Влияние включения в модель переменной, которая не должна быть включена

Допустим, что истинная модель представляется в виде:

$$y = \alpha + \beta_1 x_1 + u \quad (6.15)$$

а вы считаете, что ею является

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + u \quad (6.16)$$

и рассчитываете оценку величины b_1 , используя формулу (5.12) вместо выражения $Cov(x_1, y)/D(x_1)$.

В целом проблемы смещения здесь нет, даже если b_1 будет рассчитана неправильно. Величина $M(b_1)$ (математическое ожидание оценки) остается равной β_1 , но в общем оценка будет неэффективной. Она будет более неустойчивой, в смысле наличия большей дисперсии относительно β_1 , чем при правильном вычислении. Это проиллюстрировано на рис. 6.2.

(Эффективная оценка – это несмещенная оценка, имеющая наименьшую дисперсию среди всех несмещенных оценок. **Несмещенной** называют статистическую оценку, математическое ожидание которой равно оцениваемому параметру. **Смещенной** называют статистическую оценку, математическое ожидание которой не равно оцениваемому параметру.)



b_1

Рис.6.2. Функция плотности вероятности

Это можно легко объяснить интуитивно. Истинная модель может быть записана в виде:

$$y = \alpha + \beta_1 x_1 + 0x_2 + u \quad (6.17)$$

Таким образом, если вы строите регрессионную зависимость y от x_1 и x_2 , то b_1 будет являться несмещенной оценкой величины β_1 , а b_2 будет несмещенной оценкой нуля (при выполнении условий Гаусса-Маркова). Практически вы обнаруживаете для себя, что β_2 равно нулю. Если бы вы заранее поняли, что β_2 равно нулю, то могли бы использовать эту информацию для исключения x_2 и применить парную регрессию, которая в данном случае является более эффективной (**эффективная оценка — это та, у которой дисперсия минимальна**).

Утрата эффективности в связи со включением x_2 в случае, когда она не должна была быть включена, зависит от корреляции между x_1 и x_2 . Сравните дисперсии величины b_1 при построении парной и множественной регрессии (табл. 6.5).

Дисперсия в общем окажется большей при множественной регрессии, и разница будет тем большей, чем ближе коэффициент корреляции к единице или -1. Единственным исключением в связи с проблемой утраты эффективности является вариант, когда коэффициент корреляции точно равен нулю. В этом случае оценка b_1 для множественной регрессии совпадает с оценкой для парной регрессии. Доказательство этого опустим, поскольку оно довольно простое.

В выводе о несмещенности есть одно исключение, которое необходимо иметь в виду. Если величина x_2 коррелирует с u , то коэффициенты регрессии будут в конечном счете смещенными. Если модель записать как уравнение (6.17), то это будет означать, что четвертое условие Гаусса-Маркова применительно к величине x_2 не выполняется.

Иллюстрация, основанная на эксперименте по методу Монте-Карло

В эксперименте по методу Монте-Карло, описанном в разделе 6.2, исследователь переоценил влияние образования на доход из-за того, что он не учел зависимости дохода в данной стране от величины IQ и того обстоятельства, что величина S там отчасти играла роль замещающей переменной для IQ в неправильно специфицированном уравнении парной регрессии. Будем помнить об этом и предположим, что наш исследователь, являющийся уже экспертом в данном вопросе, приглашен в качестве консультанта для проведения аналогичного исследования в соседней стране.

Может оказаться, что в новой стране подход более формален, чем в первой, и доход здесь определяется только образованием (и удачей) без учета способностей как таковых. Пусть базовый доход здесь снова равен 10 000, с добавлением 2000 за каждый год учебы сверх минимальных 10 лет, плюс (или минус) некоторая величина, зависящая от фактора удачи. Истинным соотношением поэтому будет:

$$y = 10\,000 + 2000(S - 10) + u = -10\,000 + 2000S + u \quad (6.18)$$

Исследователь снова делает выборку из 20 человек, и по

удивительному совпадению все они имеют одинаковые характеристики, показанные в первой части табл. 5.2. В этом случае имеются также данные о величине ***IQ***. Считая, что включение величины ***IQ*** в уравнение регрессии не причинит вреда, исследователь проводит эту операцию и получает следующее соотношение (стандартные ошибки указаны в скобках):

$$\hat{y} = -13\,336 + 2140S + 18IQ. \quad (6.19)$$

(4155) (151) (43)

Результат действительно неплохой. 95-процентный доверительный интервал для константы включает в себя ее истинное значение —10 000, и аналогичный интервал для ***S*** включает значение 2000. Таким образом, полученные оценки незначимо отличаются от истинных величин с 5-процентным уровнем значимости. Точно так же коэффициент ***IQ*** незначимо отличается от нуля.

Если бы при этом была использована правильная спецификация, то результатом было бы:

$$\hat{y} = -11\,782 + 2163S. \quad (6.20)$$

(с.о.) (1851) (137)

Оценка константы здесь лучше, однако оценка коэффициента при переменной ***S*** недостаточно хороша (влияние фактора удачи оказалось относительно незначительным).

И вновь здесь нельзя слишком полагаться на результаты одного эксперимента.

<i>Эк пери мент</i>	<i>Правильная спецификация</i>				<i>Спецификация исследователя</i>					
	<i>Конс танта</i>	<i>с.о.</i>	<i>S</i>	<i>с.о.</i>	<i>Конс танта</i>	<i>с. о.</i>	<i>S</i>	<i>с.о.</i>	<i>IQ</i>	<i>с. о.</i>
1	-11781	185	2163	137	-13336	4155	2140	151	18	43
2	-11940	249	215	184	-3019	5067	2290	184	-10	52
3	-7092	234	182	173	-11463	5150	1755	187	51	53
4	-7152	213	172	158	-15371	4273	1597	155	95	44
5	-9116	204	195	151	-14535	4371	1872	158	63	45
6	-12446	157	2230	116	-16742	3352	2167	121	50	35
7	-12510	246	2177	182	-6727	5329	2263	193	-67	55
8	-11487	236	2164	175	-18187	5005	2065	181	77	52
9	-4733	232	1644	172	-5384	5354	1634	190	8	54
10	-13742	194	2290	144	-13839	4386	2289	159	1	45

В табл. 6.6 сведены вместе результаты повторения еще девяти таких же экспериментов с изменением в каждой выборке только значений случайной составляющей. Из табл. 6.6 можно сделать следующие выводы.

1. Результаты исследователя не выглядят смещенными, даже если спецификация является неправильной. Оценка константы колеблется около —10 000, а оценка коэффициента величины ***S***

— около 2000. (Естественно, что результаты оценивания правильной спецификации тоже будут несмещенными.)

2. Результаты оценивания правильной спецификации в целом более точны, поскольку эта спецификация оказывается более эффективной. Но данное утверждение не всегда верно, и в ряде случаев неправильная спецификация дает результат ближе к истине. Причиной этого является то, что относительная неэффективность спецификации исследователя зависит от корреляции между S и IQ , а корреляция оказывается не достаточно тесной (в выборке из табл. 6.1), чтобы вызвать большие расхождения с истинными значениями.
3. Более высокая эффективность правильной спецификации должна отражаться в меньших стандартных ошибках, и это в целом действительно подтверждается.
4. Оценки коэффициентов при IQ в спецификации исследователя в целом незначительно отличны от нуля. В эксперименте 4 имеется единственное отклонение, когда истинная гипотеза о нулевом значении отвергается при 5-процентном уровне значимости. Это является хорошим примером ошибки I рода (см. Обзор).